La gestion des heures supplémentaires dans une collectivité territoriale suppose que chaque agent déclare ses horaires, que son responsable valide les données saisies et que le service des ressources humaines contrôle ensuite la cohérence des totaux avant la paie.

Lorsque les documents sont numérisés ou convertis d'un format bureautique vers un format de diffusion, la restitution du texte dépend du moteur qui a produit le fichier, de la façon dont les espaces ont été encodés et de la justification des lignes.

Les notices d'utilisation, les rapports annuels, les délibérations et les courriers contiennent des phrases longues, des listes à puces, des intitulés en gras et des notes de bas de page qui mettent à l'épreuve les algorithmes d'extraction fondés sur la position des caractères.

Un lecteur humain ne remarque pas qu'une espace est absente tant que les lettres sont correctement alignées ; un moteur d'indexation, lui, découpe les mots d'après les espaces et perd alors toute possibilité de retrouver les termes recherchés par les utilisateurs.

Il convient donc de mesurer, sur des fichiers variés, la proportion de mots collés produite par chaque chaîne de conversion, plutôt que de supposer qu'un défaut observé sur un document se retrouve sur tous les autres.

La gestion des heures supplémentaires dans une collectivité territoriale suppose que chaque agent déclare ses horaires, que son responsable valide les données saisies et que le service des ressources humaines contrôle ensuite la cohérence des totaux avant la paie.

Lorsque les documents sont numérisés ou convertis d'un format bureautique vers un format de diffusion, la restitution du texte dépend du moteur qui a produit le fichier, de la façon dont les espaces ont été encodés et de la justification des lignes.

Les notices d'utilisation, les rapports annuels, les délibérations et les courriers contiennent des phrases longues, des listes à puces, des intitulés en gras et des notes de bas de page qui mettent à l'épreuve les algorithmes d'extraction fondés sur la position des caractères.

Un lecteur humain ne remarque pas qu'une espace est absente tant que les lettres sont correctement alignées ; un moteur d'indexation, lui, découpe les mots d'après les espaces et perd alors toute possibilité de retrouver les termes recherchés par les utilisateurs.

Il convient donc de mesurer, sur des fichiers variés, la proportion de mots collés produite par chaque chaîne de conversion, plutôt que de

supposer qu'un défaut observé sur un document se retrouve sur tous les autres.